游戏助手服务配置文件说明

目录

1 游戏助手服务配置文件说明 **1**

2 更新日志 **1**
- 2.1 2026-08-13 . . . 1
- 2.2 2026-08-05 . . . 2
- 2.3 2025-08-18 . . . 2
- 2.4 2025-06-11 . . . 2
- 2.5 2025-06-03 . . . 2
- 2.6 2025-05-29 . . . 2
- 2.7 2025-05-09 . . . 2
- 2.8 2025-04-25 . . . 2

3 配置文件 **2**
- 3.1 完整内容 . . . 2

4 各模块配置说明 **4**
- 4.1 saves . . . 4
- 4.2 server . . . 4
- 4.3 caller . . . 4
- 4.4 vision . . . 4
  - 4.4.1 query . . . 5
- 4.5 knowledge . . . 5
  - 4.5.1 query . . . 5
- 4.6 llm . . . 6
  - 4.6.1 model . . . 6
  - 4.6.2 args . . . 6
- 4.7 embedding . . . 7
  - 4.7.1 model . . . 7
- 4.8 asr . . . 7
  - 4.8.1 speech_model . . . 7
  - 4.8.2 punc_model . . . 7
- 4.9 vlm . . . 7
  - 4.9.1 model . . . 8
  - 4.9.2 args . . . 8

1 游戏助手服务配置文件说明

编辑日期 `2026-08-17` 。
游戏助手服务版本 `2026-08-17` 。

2 更新日志

2.1 2026-08-13

- 配置项 `knowledge` 的 `query` 新增 `rerank_candidates` 、`hybrid` 、`multi_query` 、`context_expand` 、`refusal_message` ； `topk` 默认值由 3 改为 8。

- 配置项 `llm.args` 中 `do_sample` 默认值由 `true` 改为 `false` 。

2.2 2026-08-05

- 增加配置项 `server.timeout_graceful_shutdown` 。

2.3 2025-08-18

- 删除配置项 `llm.model.support_system_role` 。

2.4 2025-06-11

- 配置项 `llm.model` 增加 `ov_cache` 。
- 配置项 `embedding.model` 增加 `ov_cache` 。

2.5 2025-06-03

- 配置项 `server` 增加 `单实例模式` 。

2.6 2025-05-29

- 增加配置项 `server` 。
- 配置项 `caller` 增加 `父进程监控` 。

2.7 2025-05-09

- 增加配置项 `caller` 。
- 增加 `llm` 配置项 `device` 。
- 增加 `embedding` 配置项 `device` 。
- 增加 `asr` 配置项 `speech_model` 和 `punc_model` 。

2.8 2025-04-25

- 初版。

- 提供 `配置文件` 说明。

3 配置文件

3.1 完整内容

配置文件名为 `gameassistanttoolserver.json` 。

```
{
    "saves": {
        "path": "saves"
    },
    "server": {
        "host": "127.0.0.1",
        "port": 9190,
        "singleton": false,
        "timeout_graceful_shutdown": 15
    },
    "caller": {
        "monitor_parent": false,
        "processes": [],
        "interval": 5
    },
```

```
    "vision": {
        "enable": true
    },
    "knowledge": {
        "enable": true,
        "query": {
            "topk": 8,
            "threshold": 0.5,
            "rerank_candidates": 100,
            "hybrid": {
                "enable": true,
                "bm25": {
                    "tokenizer": "jieba",
                    "k1": 1.5,
                    "b": 0.75
                },
                "rrf_k": 60
            },
            "multi_query": {
                "enable": false,
                "max_queries": 3,
                "max_new_tokens": 128
            },
            "context_expand": {
                "enable": true,
                "window": 2,
                "max_chars": 4000
            },
            "refusal_message": " 在知识库中没有找到足够的相关信息。",
            "extra":{
                "topk": 2,
                "threshold": 0.5
            }
        }
    },
    "llm": {
        "enable": true,
        "model": {
            "path": "models/llm",
            "device": "iGPU",
            "trust_remote_code": true,
            "use_cache": true,
            "ov_cache": null
        },
        "args": {
            "top_k": 1,
            "top_p": 1.0,
            "temperature": 0.7,
            "repetition_penalty": 1.0,
            "max_length": 2048,
            "max_new_tokens": 256,
            "do_sample": false
        }
    },
    "embedding": {
        "enable": true,
        "model": {
            "path": "models/emb",
```

```
            "device": "iGPU",
            "ov_cache": null
        }
    },
    "asr": {
        "enable": true,
        "speech_model": {
            "path": "models/asr/speech",
            "device": "CPU"
        },
        "punc_model": {
            "path": "models/asr/punc",
            "device": "CPU"
        }
    }
}
```

4 各模块配置说明

4.1 saves

数据存储相关配置。

- `path` ：String 类型。游戏助手服务数据保存路径。

4.2 server

服务地址和端口配置。

- `host` ：String 类型。服务 IP 地址，如果填 `127.0.0.1` 则仅允许本机访问，如果填 `0.0.0.0` 则允许公网访问。
- `port` ：Int 类型。服务端口号，如果填 `0` ，启动会随机分配一个端口号。关于如何获取端口号，请参考《游戏助手服务 Runtime 配置文件说明》。
- `singleton` ：Bool 类型。是否启用单实例模式。如果填 `true` ，那么同一时间只能有一个服务端运行。如果填 `false` ，那么同一时间可以有多个服务端同时运行。
- `timeout_graceful_shutdown` ：Int 类型。服务端接收到 shutdown 接口请求后，将在指定时间后强制结束所有正在执行中的任务，然后退出。

4.3 caller

游戏助手服务调用者相关配置。
当指定调用者进程或监控父进程时，会定时查询调用者进程和父进程是否存在，只有都不存在的情况下，游戏助手服务才会自动退出。
如果 `processes` 列表为空且不监控父进程，不做任何查询，游戏助手服务不会自动退出。

- `monitor_parent` ：Bool 类型。是否监控父进程。
- `processes` ：List[String] 类型。调用者进程名，区分大小写，需带有后缀名，比如 `GameAssistantToolServer.exe` 。
- `interval` ：Float 类型。查询调用者进程间隔时间，单位：秒。

4.4 vision

Vision 接口相关配置。

- `enable` ：Bool 类型。启动服务时是否启用 Vision 接口。默认启用， `true` 表示启用， `false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `Vision 服务` 的 `/vision/service/enable/{enable}` 接口。

4.4.1 query

Vision 的 Query 接口相关配置。

- `topk` ：Int 类型。Query 接口返回多少个结果。默认 1 个，可以通过接口指定。

4.5 knowledge

知识库接口相关配置。

- `enable` ：Bool 类型。启动服务时是否启用知识库接口。默认启用，`true` 表示启用，`false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `知识库服务` 的 `/knowledge/service/enable/{enable}` 接口。

4.5.1 query

知识库的 Query 接口相关配置。
查询流程：多查询改写（可选）→ 稠密向量 + BM25 词法混合检索 → RRF 融合 → 重排序 → 按 `threshold` 相关性门控 → 上下文扩展（相邻块补齐）→ 编号化后交给 LLM 回答。

- `topk` ：Int 类型。重排序并门控后，最终返回给 LLM 的知识块数量。默认 8。
- `threshold` ：Float 类型。重排序分数低于 `threshold` 的知识块会被剔除；若全部被剔除，接口直接返回 `refusal_message` 拒答消息（不调用 LLM）。默认 0.5。可通过查询接口的 `threshold` 参数临时覆盖。
- `rerank_candidates` ：Int 类型。重排序前保留的候选知识块数量（混合检索 RRF 融合后的候选池大小）。默认 100。
- `refusal_message` ：String 类型。检索不到足够相关知识时的拒答消息。

4.5.1.1 hybrid 混合检索配置：稠密向量（Embedding）与 BM25 词法检索双路召回，用 RRF 融合排名，显著提升游戏名词、道具名等精确词的召回稳定性。关闭后仅使用稠密向量检索。

- `enable` ：Bool 类型。是否启用混合检索。默认 `true` 。
- `rrf_k` ：Int 类型。RRF（Reciprocal Rank Fusion）融合参数 `k` 。默认 60。
- `bm25` ：BM25 词法检索参数。
  - `tokenizer` ：String 类型。分词方式，可选 `jieba` （默认）或 `bigram` ；`jieba` 不可用时自动回退 `bigram` 。
  - `k1` ：Float 类型。词频饱和参数。默认 1.5。
  - `b` ：Float 类型。文档长度归一化参数。默认 0.75。

4.5.1.2 multi_query 多查询改写配置。启用后，查询前用 LLM 把用户问题改写成多条检索子查询（覆盖别名、同义词、补全缺失名词），合并检索提升召回。注意：每次问答会额外产生一次 LLM 调用，会增加延迟（iGPU 上约 2~3 秒）。
改写使用的 prompt 为领域中性模板（游戏、小说等任意知识库通用），默认按 `splitter.language` 选择中文或英文，占位符为 `{max_queries}` 、`{message}` ；可通过 `< 服务端根目录 >\prompts\multi_query_prompt.txt` 文件覆盖（同占位符约定，如无该文件则使用内置模板）。

内置的 `改写提示词模板` 如下

```
你是检索查询改写助手。请把下面的用户问题改写为若干条用于知识库检索的独立查询。
要求：
1. 覆盖用户可能使用的同义词、别名，补全缺失的专有名词（人名、地名、物品名、事件名等）。
2. 最多输出 {max_queries} 条，每条一行，直接输出查询内容，不要编号、不要解释、不要引号。
用户问题：{message}
```

- `enable` ：Bool 类型。是否启用多查询改写。默认 `true` （本发布示例中为 `false` ）。
- `max_queries` ：Int 类型。最多生成的子查询数量（含原文）。默认 3。
- `max_new_tokens` ：Int 类型。改写生成的最大 token 数。默认 128。

4.5.1.3 context_expand 上下文扩展配置。启用后，把命中知识块的相邻块（同一来源文件，前后各 `window` 个）一并喂给 LLM，避免固定大小分块把一段完整攻略拦腰截断。

- `enable` ：Bool 类型。是否启用上下文扩展。默认 `true` 。
- `window` ：Int 类型。命中块前后各补多少个相邻块。默认 2。
- `max_chars` ：Int 类型。扩展后上下文的字符数上限。默认 4000。

4.5.1.4 extra 额外查询知识库时的相关配置。
关于 `额外查询知识库` ，请查看 `游戏助手服务接口说明` 中 `知识库服务` 的 `/knowledge/service/query/{instance_id}` 接口的 `extra_info` 参数。

- `topk` ：Int 类型。额外搜索知识库，返回最匹配的 `topk` 个知识。
- `threshold` ：Float 类型。额外搜索知识库，保留匹配分数高于 `threshold` 的知识。

4.6 llm

知识库接口中的大语言模型相关参数。

- `enable` ：Bool 类型。启动服务时是否启用大语言模型。默认启用， `true` 表示启用， `false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `知识库服务` 的 `/knowledge/service/llm/enable/{enable}` 接口。

4.6.1 model

模型相关配置。

- `path` ：String 类型。模型所在的文件夹路径。
- `device` ：String 类型。模型运行在指定设备上。可选项有 `CPU` 、 `iGPU` 、 `dGPU` 。
- `trust_remote_code` ：Bool 类型。请根据模型做相应修改。
- `use_cache` ：Bool 类型。请根据模型做相应修改。
- `ov_cache` ：String 类型。设置模型缓存位置。如果是 `null` 或 `空字符串` ，表示禁用模型缓存，如果是 `文件夹路径` ，则会自动创建文件夹，并在其中创建模型缓存文件。

4.6.2 args

模型参数相关配置。
如果

- `top_k` ：Int 类型。取概率最高的 K 个 Token 作为候选。
- `top_p` ：Float 类型。取 N 个概率总和低于 `top_p` 的 Token 作为候选。
- `temperature` ：Float 类型。取值越低，概率越高的 Token 越容易被选中。取值越高，所有候选 Token 被选中的概率趋近于一致。
- `repetition_penalty` ：Float 类型。值 1.0 表示对于重复出现的 Token 不作惩罚，即不降低选中概率。取值越高，惩罚越大。如需要，建议取 1.2。
- `max_length` ：Int 类型。限制生成的 Tokens 个数。与 `max_new_tokens` 冲突。
- `max_new_tokens` ：Int 类型。限制生成新 Tokens 的个数，已生成过的 Token 再次被生成则不算数。与 `max_length` 冲突。

- `do_sample` ：Bool 类型。`true` 表示从候选 Token 中取样。`false` 表示取概率最高的 Token，等同于 `top_k` 取值 1。
- `enable_thinking` ：Bool 类型。是否开启思考模式，默认 `false` 。开启后模型先输出思考过程再给出回答。可通过 OpenAI 兼容接口 `/v1/chat/completions` 的 `enable_thinking` 请求参数覆盖。当前 `optimum` 和 `genai` 两个后端均支持。

4.7 embedding

知识库接口中的 Embedding 模型相关参数。

- `enable` ：Bool 类型。启动服务时是否启用 Embedding 模型。默认启用，`true` 表示启用，`false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `知识库服务` 的 `/knowledge/service/embedding/enable/{enable}` 接口。

4.7.1 model

模型相关配置。

- `path` ：String 类型。模型所在的文件夹路径。
- `device` ：String 类型。模型运行在指定设备上。可选项有 `CPU` 、 `iGPU` 、 `dGPU` 。
- `ov_cache` ：String 类型。设置模型缓存位置。如果是 `null` 或 `空字符串` ，表示禁用模型缓存，如果是 `文件夹路径` ，则会自动创建文件夹，并在其中创建模型缓存文件。

4.8 asr

语音识别接口中的模型相关参数。

- `enable` ：Bool 类型。启动服务时是否启用语音识别模型。默认启用，`true` 表示启用，`false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `ASR 服务` 的 `/asr/service/enable/{enable}` 接口。

4.8.1 speech_model

语音模型相关配置。

- `path` ：String 类型。模型所在的文件夹路径。
- `device` ：String 类型。模型运行在指定设备上。可选项有 `CPU` 、 `iGPU` 、 `dGPU` 。

4.8.2 punc_model

语音标点符号模型相关配置。

- `path` ：String 类型。模型所在的文件夹路径。
- `device` ：String 类型。模型运行在指定设备上。可选项有 `CPU` 、 `iGPU` 、 `dGPU` 。

4.9 vlm

VLM（多模态）接口相关配置。配置文件为独立的 `config/vlm.json` 。

完整内容：

```
{
    "vlm": {
        "enable": true,
        "model": {
            "path": "models/vlm",
            "device": "dGPU",
            "backend": "optimum",
            "trust_remote_code": true,
```

```
            "use_cache": true,
            "ov_cache": "caches/models/vlm",
            "min_pixels": 200704,
            "max_pixels": 1003520
        },
        "args": {
            "top_k": 1,
            "top_p": 1.0,
            "temperature": 0.7,
            "repetition_penalty": 1.0,
            "max_new_tokens": 1024,
            "do_sample": true,
            "enable_thinking": false,
            "timeout": 120,
            "skip_prompt": true,
            "skip_special_tokens": true
        }
    }
}
```

- `enable` ：Bool 类型。启动服务时是否启用 VLM。默认启用，`true` 表示启用，`false` 表示禁用。可通过接口开关服务，详见 `游戏助手服务接口说明` 中 `VLM 服务` 的 `/vlm/service/enable/{enable}` 接口。

4.9.1 model

模型相关配置。

- `path` ：String 类型。模型所在的文件夹路径。
- `device` ：String 类型。模型运行在指定设备上。可选项有 `CPU` 、`iGPU` 、`dGPU` 、`NPU` 。
- `backend` ：String 类型。VLM 推理后端，默认 `optimum` 。可选项：
  - `optimum` ：基于 OpenVINO + Optimum，支持 `enable_thinking` 思考模式开关。
  - `genai` ：基于 OpenVINO GenAI。
- `trust_remote_code` ：Bool 类型。请根据模型做相应修改。
- `use_cache` ：Bool 类型。请根据模型做相应修改。
- `ov_cache` ：String 类型。设置模型缓存位置。如果是 `null` 或 `空字符串` ，表示禁用模型缓存，如果是 `文件夹路径` ，则会自动创建文件夹，并在其中创建模型缓存文件。
- `min_pixels` ：Int 类型。输入图片的最小像素数限制。
- `max_pixels` ：Int 类型。输入图片的最大像素数限制。

4.9.2 args

模型生成参数相关配置。除下述参数外，与 `llm.args` 相同的 `top_k` 、`top_p` 、`temperature` 、`repetition_penalty` 、`max_new_tokens` 、`do_sample` 等参数同样适用。

- `enable_thinking` ：Bool 类型。是否开启思考模式，默认 `false` 。开启后模型先输出思考过程再给出回答。可通过 OpenAI 兼容接口 `/v1/chat/completions` 的 `enable_thinking` 请求参数覆盖。注意：该参数是否生效取决于 `backend` 与模型（`optimum` 后端支持；`genai` 后端部分模型可能不响应）。
- `timeout` ：Int 类型。生成超时时间，单位：秒。
- `skip_prompt` ：Bool 类型。是否在返回中忽略提示词部分。

- `skip_special_tokens` : Bool 类型。是否在返回中忽略特殊 token。